

Reti e Sistemi Operativi

DaveRhapsody

3 Ottobre 2019

Indice

Capitolo 1

La rete

La rete è un insieme di nodi, che sono tendenzialmente pc, server, terminali, e dispositivi radio che consentono ai dispositivi senza fili di collegarsi (per intenderci, gli access point wi-fi), ma attenzione!

Qui si parla di wi-fi, non della rete a cella telefonica, non si parla di 4G etc.

1.1 Il modello TCP/IP

Al centro è presente un Router, dispositivo in grado di INDIRIZZARE quelli che sono i pacchetti IP (Internet Protocol). Cos'è un pacchetto?

Pacchetto : E' un "Record/Struct" composto da un campo dati detto payload), ed un campo header, che serve al protocollo di riferimento come etichetta che dice (ad un protocollo) "Questo pacchetto lo puoi leggere". Cosa contiene l'Header?

$$header = \begin{cases} indirizzi \\ livelli di priorit \\ contatori \end{cases}$$

A che servono i contatori?

Immagina di avere un problema nella rete in cui appare un routing loop (pensate alla lista circolare)

I pacchetti è auspicabile che siano di dimensioni piccole, immaginate un film di dimensioni tendenti al Gigabyte, un pacchetto da un Giga è pressochè (ad oggi) insostenibile, pertanto, si riduce in pezzettini. Soprattutto c'è una probabilità di errore più bassa! (Pensate di mangiarvi una Fiorentina in un solo boccone o di tagliarla prima un pochino, stesso concetto.)

Un altro motivo per cui vengono usati i pacchetti è legato al fatto che inviare un qualsiasi dato occupa un canale. Intendiamoci, se da A a B (terminali) abbiamo un solo cavo, non c'è problema, no?

Ok, ma se A e B sono degli switch aventi 10 pc connessi assieme? Se uno deve caricare un giga di roba la gente deve aspettare che questo finisca MA utilizzando un sistema

a pacchetti, otteniamo che ci sia una sorta di "turno" per ogni pacchetto. Di conseguenza non si intasa la luce.

Il sistema sopracitato si chiama multiplazione o multiplexing statistico, perchè quando io metto tanti flussi di info che viaggiano sullo stesso collegamento, potrebbero accadere congestioni di rete, oppure comunque uno deve aspettare. Ecco i pacchetti dei pacchetti che attendono si chiama buffer. Più hai host di rete, più ti conviene aumentare la dimensione del buffer.

Lo switch Sono dei dispositivi che consentono di costruire la rete con più livelli, proprio perchè ad essi vengono collegati altri dispositivi. Uno switch utilizza connessioni Ethernet, ed una serie di nodi collegati ad uno switch forma una LAN. ATTENZIONE, quando si menziona l'access point, la rete che si forma si chiama WLAN, ovvero (Wireless LAN (Local area network)).

Terminale Il terminale (o host) sarà tendenzialmente un qualsiasi dispositivo che hosta applicazioni che lavorano in rete.

ATTENZIONE la rete è identificata dal Router.
Quando noi diciamo Internet, di fatto, stiamo parlando di un insieme di reti, appunto inter - net, più reti, ergo, più router. C'è un agreement totale che consente ad un terminale in una zona, per poter arrivare ad un'altra.

Vi ricordate il cammino dei nodi? Ecco, stesso concetto.
Questi nodi che si attraversano per passare da una rete A ad una rete B si chiamano autonomous systems, ed il cammino tra mittente e destinatario di un messaggio è identificato dagli autonomous per cui il pacchetto passo.

Più precisamente questi Autonomous sono dei Gateway, gestiti con un protocollo (BGP, Border Gateway Protocol) in grado di regolare le comunicazioni tra questi AS.
Ogni sistema autonomo, a sua volta all'interno avrà un certo insieme di altri router e reti, e quindi sarà presente un altro protocollo (IGP, Internal gateway protocol).

Sicurezza di un AS Ogni sistema autonomo è gestito da un "master" in grado di poter decidere cosa possa passare da quella rete, specifica le famose policy di Routing. La domanda che sorge è.. Chi gestisce gli AS in toto? I gestori della rete, quelli telefonici.

1.2 Cosa influenza le prestazioni di una rete?

Analizzeremo due quantità

Latenza/ritardo La latenza (o ritardo) non è altro che il tempo che intercorre tra l'invio e la ricezione di un pacchetto. Esistono diversi tempi:

- Tempo di processing: E' una quantità infinitesimale che indica il tempo impiegato per elaborare un pacchetto

- Tempo di coda: Per misurarlo devo capire oggettivamente quanto viene usata quella coda (esistono interi studi sulle code, ma a noi ci importa una bellissima ;) (Almeno, per questo corso si intende))

Per un sistema stabile è auspicabile che il rapporto tra i dati contenibili nel buffer ed il rate di dati trasmessi al secondo sia ≤ 1 , detto meglio:

$$\frac{nL}{R} \leq 1$$

Throughput Il through put è il quantitativo di dati che riescono ad essere trasferiti in un determinato quantitativo di tempo (Avete presente Mbps, Gbps, Kbps, quella roba lì)

1.3 Stratificazione

Il concetto di stratificazione consiste nel includere le funzioni di una rete non in un solo protocollo ma in una serie di protocollo che abbiano uno specifico compito, e sia indipendente dagli altri

La filosofia KISS Keep it simple stupid, è la filosofia che regola anche il mondo Unix e Gnu/Linux, ovvero, ogni componente fa il suo mestiere, fa la sua funzione, evitare di mettere in mano ad un componente 10 compiti diversi, per intenderci.

Inoltre dividendo in più componenti io ho possibilità di testare il singolo componente, il singolo protocollo, il singolo problema SENZA, S E N Z A andare a danneggiare o danneggiare gli altri protocolli/componenti!

Stack ISO/OSI Questo è lo stack più preciso ingrandito dell'TCP/IP, visto dal livello più basso al livello più alto

- physical
- data link
- network
- transport
- session
- presentation
- application

1.4 livello Physical

Nel livello fisico viene convertito quello che è il segnale elettrico in una sequenza di 0 ed 1

1.5 Livello Data Link

Si implementa MAC (Medium Access Control), converte quelli che erano degli 0 ed 1 e li fa diventare dei pacchetti (yes, c'è il primo header, cioè quello del physical).

L'indirizzo MAC identifica univocamente un dispositivo in rete, QUALSIASI esso sia. E non solo, mondialmente, N O N esistono due dispositivi DIVERSI aventi lo STESSO Mac address. A che serve oltre questo? Serve al protocollo ip per capire CHI è il mittente o destinatario, e sì, è incluso nell'header

1.6 Rete

E' il livello di internet, l'IP protocol, con indirizzo ipv4 v6 etc.

1.7 Trasporto

E' il livello in grado di trasportare tramite internet quelli che sono i pacchetti applicazione, trasporta i datagram ip, trasporta i pacchetti appunto tramite internet, sono presenti due protocolli (TCP e UDP) che si occupano di fare questo

1.8 Applicazioni

Il nome parla da sè, non lo studieremo in questo corso.

Qui noi si studierà dal data link al transport MA in ordine invertito, ovvero partiamo da "Che cosa vuole l'applicazione?" e poi andiamo a scalare.

Precisazione: Dato un pacchetto in un qualsiasi livello (escluso lv application), quando viene aggiunto l'header, il nuovo pacchetto potrà esser letto SOLO dal protocollo del livello superiore!

Su questo stesso piano, se ho un pacchetto con già l'header aggiunto, questo potrà essere spaccettato SOLO da un protocollo del livello inferiore.

Ogni livello offre servizio al livello immediatamente superiore od inferiore in base al verso del flusso dati.

La magica teoria (o ricetta) dell'incapsulamento di Dave Per spiegare meglio cosa accade, immaginatevi una fetta di prosciutto, bene, questa fetta di prosciutto rappresenta il **flusso elettrico** che vien gestito dal livello fisico.

A questo punto, immaginatevi due fette di pane che si chiudono sulla fetta di prosciutto. Benissimo, il Data Link ha **INCAPSULATO** il prosciutto ed ha creato un panino (**Pacchetto**)!

Il data link passerà questo panino al **Network** , e lì ci saranno altre due fette di pane che includeranno il nostro panino. Ed in questo modo abbiamo ottenuto un panino dentro ad un altro panino! Ossia, un pacchetto incapsulato in un pacchetto che semplicemente aggiunge un header (o intestazione) ;) Ma torniamo seri adesso.

[Premete qui per vedere un video corso che spiega con precisione l'incapsulamento.](#)

Capitolo 2

Livello Trasporto

Il livello di trasporto è il livello che riceve messaggi dal livello application ed ha come compito quello di mettere in comunicazione end-to-end due nodi. Nel caso del livello di trasporto non si parla di pacchetti ma di Segmenti (Dall'esempio sopra riportato sì, è stato incapsulato il pacchetto del lv network).

Quando viene analizzato il segmento si effettua la DEMULTIPLAZIONE (Demultiplexing), ovvero si analizza l'header del segmento per vedere a quale applicazione sarà destinataria di un determinato messaggio.

Cosa contiene un segmento di trasporto?

- Numero di porta: presente in ogni segmento, rappresenta una applicazione e dal punto di vista dell'applicazione è come se fosse un punto di accesso, detto anche SOCKET.

NON CONFONDIAMOCI Il livello transport vede una porta, mentre il livello applicazione vede un socket. All'atto pratico c'è una syscall che letteralmente può attivare qualsiasi socket.

- Protocollo Transport TCP o UDP.

Che differenza c'è tra TCP e UDP? UDP è quello che usate negli streaming di Rojadirecta , in cui pur di vedere la vostra squadra (che ovviamente è la Fiorentina, vero? <3) non vi preoccupate di perdere qualche dato (tipo immagine un po' sgranata ogni tanto e simili).

Infatti UDP se ne frega se un pacchetto è arrivato, è usato per comunicazioni anche per esempio le voice chat, roba di questo genere, poichè **NON** effettua alcun controllo sulla correttezza dei messaggi, diciamo che lui ti invia roba, se non ti arriva non gli importa, va avanti, perchè qui è importante che si sia il più aggiornati possibile. Al contrario TCP effettua questi controlli, perchè con TCP si garantisce la correttezza (sia dei dati stessi che dell'ordine in cui arrivano), pertanto potrebbe essere un problema.

Il segmento può avere sia TCP che UDP, e nel caso di UDP si ha un IP + Porta di

destinazione, o meglio

$$PacchettoUDP = \begin{cases} SourcePort : Porta sorgente \\ DestinationPort : Porta di destinazione \\ Lunghezza : Indica la lunghezza totale del segmento (+payload dei livelli inferiori) \\ Checksum : Verifica la correttezza di trasmissione \end{cases}$$

Supponiamo di avere un web server, (quello che consente di vedere una pagina web) , la porta d'accesso è la stessa ma hai più utenti con la stessa pagina

Nel caso di TCP invece un segmento è composto non solo dall'IP + la porta di destinazione, ma è composto in questo modo:

$$\begin{cases} IP_A \\ IP_B \\ PORT_A \\ PORT_B \end{cases}$$

A e B in questo caso sono tendenzialmente sorgente e destinataria, ed il calcolo del checksum precedente è effettuato direttamente dal livello Transport stesso.

Attenzione, nell'introduzione abbiamo anche detto che già nel datalink abbiamo dei controlli, pertanto ogni livello può svolgere la correzione dei pacchetti, pertanto non si attiva quasi mai, perchè Transport dà per scontato che Network e Datalink gli abbiano passato qualcosa di corretto.

Il codice di implementazione del controllo è tipo di migliaia di righe di codice per correggere o prevenire errori, ed è giustissimo così. Contiamo che ormai TCP e UDP non si possono rompere, sono più che sicuri.

2.1 TCP

Il concetto è che si vuole trasferire dati in modo affidabile, o meglio, si vuole fare in modo che i dati arrivino a destinazione e siano corretti in generale.

Il trasferimento dati affidabile dipende da una serie di fattori, e si verifica quando ho una rete con le seguenti caratteristiche:

1. Nessuna perdita
2. Nessun errore
3. I dati son corretti e presenti tutti quanti

Nel caso avvengano errori si può ricorrere a diverse metodiche di soluzione, come ad esempio la tecnica di ritrasmissione. Ossia, non ti è arrivato il mio pacchetto? Ok, te lo rimando. Nell'atto pratico è una cosa del tipo

$$\begin{cases} \text{if}(\text{ricevoAcknoledgment}) \text{ then } \text{mandoSucessivo}(); \\ \text{else if}(\text{ricevoNotAcknoledgment}) \text{ rimandoPacchetto}(); \end{cases}$$

Quello che chiamo not acknoledgment (che da ora chiameremo solo ACK) viene inviato SE il pacchetto è non corretto, per esempio per il checksum.

E se il pacchetto poi è lo stesso? Ne ricevo due? No. I pacchetti sono numerati hanno un ordine, pertanto

$$\begin{cases} \text{if}(\text{ricevoACK})m + 1; \\ \text{else } m \end{cases}$$

con m che è il "pezzetto" successivo o precedente, è importante che si capisca questo.

Ora cerchiamo di integrare, è necessario che il sistema mi mandi indietro sì se ha ricevuto ma ANCHE la posizione a cui è arrivato! (Sistema PAR, positive acknoledgmente with retransmiton).

Quindi mi mandi un messaggio e io ti rispondo dicendo ok messaggio, tu mi mandi il due, io rispondo ok due, tu mi mandi tre io rispondo ok due, mi rimandi tre.

Perdite Sì, ok, ma se uno non mi riesce a rispondere? Si imposta un semplice timer la cui scadenza implica che ti rimando il pacchetto. Un po' come quando dici una cosa con la musica alta a uno e lui ti guarda tipo fisso... Passa tempo, e poi ripeti la cosa.

E se io continuo a rispondere? Lui che fa continua come un pazzo a ripetere la stessa cosa come Ciuchino che chiedeva a Shrek ogni 2 millisecondi "Siamo arrivati?"? NO! C'è un contatore che si aziona ad ogni mancata risposta, una volta che arriva ad un tot, chiudo la comunicazione.

$$\begin{cases} \text{if}(\text{timerGoesOff}) \text{ trasmetti}(\text{messaggio}_i) \text{ AND } \text{setTimer}(0); \\ \text{else if}(\text{ACK}_i) \text{ trasmetti}(\text{messaggio}_{i+1}) \text{ AND } \text{setTimer}(0); \\ \text{else } \text{trasmetti}(\text{messaggio}_i) \text{ AND } \text{setTimer}(0); \end{cases}$$

ATTENZIONE Supponendo un timer troppo corto, accadrebbe che il destinatario non fa in tempo a rispondere, e quindi il mittente rifà la domanda prima di ricevere la risposta, hai già due domande con una risposta.

All'atto pratico questo problema esiste davvero, è un problema reale, pertanto si deve riuscire a capire il modo in cui il timer vada adattato alle condizioni di rete, che a seconda del traffico può essere più lenta o anche più veloce.

2.1.1 I tempi di una connessione

Riprendiamo il concetto di latenza (tempo che intercorre tra invio e ricezione), bene, quello è concettualmente il tempo di trasmissione, da qui possiamo calcolare che

$$utilizzoRete = \frac{\frac{L}{R}}{latenza + \frac{L}{R}}$$

in cui $\frac{L}{R}$ Ha R che è la velocità di trasferimento dei pacchetti, mentre invece L sarebbe la lunghezza, ossia: $\frac{L}{R} = \frac{Lunghezza}{Velocità\ trasmissione}$ E la latenza... E' la latenza.

2.1.2 Protocolli a Finestra Scorrevole (Sliding Windows)

Io trasferisco un insieme di w pacchetti, i quali impiegheranno $w * \frac{L}{R} \geq \frac{L}{R} + RTT$ tempo ad esser trasposti, pertanto ne esce che

$$w \geq \frac{RTT \cdot R}{L} + 1$$

Questo ovviamente in mancanza di errori e perdite.

Osservazione: Stiamo ragionando su sistemi concettualmente indistruttibili, quindi diciamo che non si è quasi menzionata la possibilità che un host possa disconnettersi.

2.1.3 Go Back N

Poniamo caso che io trasmetto 5 messaggi: $m_{1,...,5}$ e mi arriva l'ok di ricezione dall'1 al 3, malgrado li abbia trasmessi tutti e 5, pertanto ciò che accade è che rinverò dal messaggio 3 in poi.

2.1.4 Selective Repeat

Traccio la vita di ogni pacchetto individualmente, ossia ritrasmetto solo il pacchetto mancante, il problemino è legato al fatto di avere tanti timer, ma oggi c'è da considerare che abbiamo processori nell'ordine dei Ghz, no problem.

Quando all'epoca il massimo processore esistente era di massimo 10 Mhz, insomma chiaro che ora essa sia la migliore delle soluzioni. Ma cosa richiede più precisamente l'SR?

- Ack individuali per ogni pacchetto
- Un timer per ogni singolo pacchetto
- Buffer sul ricevitore (E' un array di booleani all'atto pratico)

Ci sono dei casi in cui ci sono interazioni tra numero di pacchetto e dimensione finestra, ma sono problematiche di cui non approfondiamo perchè non ci interessa siccome non può praticamente mai capitare

2.2 Formato del pacchetto

- 20 byte
 - 16 bit Source + 16 bit destination port
 - 32 bit Sequence Number
Se i numeri di sequenza contassero il numero di segmenti, pensate averne 2^{32} E INFATTI, vengono contati in Byte, quindi il numero di sequenza fa riferimento al byte
 - 32 bit ACK Number
 - 8 bit di cui 4 indicano l'header length e gli altri 4 son inutilizzati
16 bit di receive window, ovvero quanti bit posso accettare
 - 16 bit di checksum + urgent data (in seguito vedremo le funzioni dei vari flag)
- Payload (χ Byte, perchè la dimensione è variabile, dipende dal carico di dati che trasporta)

Diventa ragionevole contare i Byte e non i segmenti perchè nel periodo in cui è nato TCP il costo per la banda di rete era elevato, quindi il singolo byte faceva la differenza in una trasmissione.

2.2.1 Le Flag

- CWR: Congestion window reduced
- ECE: End to End congestion
- U: Urgent Data
- P: Push
Trasmetti senza far funzionare i tuoi algoritmi che assemblano un tot di dati.
- ACK: Ti dice se è un ACK
- RST: Reset della connessione per via di un problema nella sequenza oppure il ricevitore ti chiude la porta e non apre la connessione
- SYN: Sincronizzazione, semplicemente apre la connessione
- FIN: Chiude la connessione

2.2.2 Gestione dei riscontri

Devo inviare dei pacchetti, e quindi devo riscontrarli, come si gestisce il valore dei punteggiatori?

A invia un messaggio con Seq = 10, ACK = 57, [ciao] stiamo intendendo un messaggio avente questi 3 parametri principali, li possiamo mettere pure a sistema così, per intenderci meglio:

$$messaggio = \begin{cases} Seq = 10 \\ ACK = 57 \\ [ciao] \end{cases}$$

Cosa mi aspetto come risposta? Beh io sto comunicando che siamo al 57_{esimo} ACK e al 10 byte di sequenza, pertanto tu mi aspetti che mi si dica UEH sono arrivato a 57 e mi risponde:

$$messaggio = \begin{cases} Seq = 57 \\ ACK = 14 \\ [bella] \end{cases}$$

Il concetto è che la sequenza della risposta coincide con l'ack della "domanda", sembra sbagliato, no? Bene, se ti comunico che sono a λ mi aspetti che tu mi risponda che sei arrivato alla sequenza λ . Pertanto in risposta accadrà che la sequenza dovrà coincidere con l'ack precedente.

Se all'inizio si era al segmento 10, verrà risposto che si è al segmento 57 MA quando verrà inviato di nuovo si riscalma, diciamolo in modo più sensato:

$$EstimatedRTT = (1 - \alpha) \cdot EstimatedRTT + \alpha \cdot SampleRTT$$

Con $\alpha = 0,125$ nella maggior parte dei casi (E' il valore tipico). Ed rtt che sarebbe il rounded trasmission time, cioè in parole povere il tempo che ci si impiega a trasmettere.

Tutto va in funzione di come cambia l'RTT nel tempo, conviene avere un RTT che nel tempo rimane lo stesso, non conviene avere un RTT troppo ballerino

$$DevRTT = (1 - \beta) \cdot DevRTT + \beta \cdot |SampleRTT - EstimatedRTT|$$

Dove dev sta per deviazione (O margine di sicurezza) e tipicamente $\beta=0,25$
 Infine definiamo quello che è il $Timeout = EstimatedRTT + 4 \cdot DevRTT$

2.2.3 Passo 2: Ritrasmissione

Quando non va tutto bene potrei dovere ritrasmettere dei segmenti, perchè? Generalmente per via di o timeout oppure ack duplicati.

Il nostro trasmettitore fondamentalmente trasmette segmenti, nel caso il ricevitore non riceve allora questo ritrasmette, e nelle puntate precedenti si è visto cosa può accadere (Timer e ACK duplicati), ed infine resetta il timer.

ATTENZIONE NON esiste un preciso modo per cui possano verificarsi dei problemi di ricezione, possono accadere miliardi di differenti inconvenienti, per dire anche il fatto che ti arriva un segmento a metà, l'altro solo inizio e fine

2.2.4 La perdita dei pacchetti

Se il trasmettitore invia un pacchetto che però non arriva, il ricevitore manderà l'ack precedenti dicendo che manca un pezzo, possono esserci diverse situazioni. (Si ok, perchè manda un altro ACK? Semplicemente perchè potrebbe essersi perso pure quello, non funziona una s**a in questa rete.).

2.2.5 Pacchetti che arrivano non in sequenza

Abbiamo visto il selective Repeat, ma c'è anche un altro modo un po' diverso che ha un unico timer (soluzione che impiega più ram che processore) perchè sul trasmettente avremo un array di ack che dice dove e cosa è stato ricevuto. Esempio:

Io invio da 1 fino a 5, mi rispondi 4, io ti mando poi 6, 7, 8, allora in base a quale elemento dell'array non risulta true io ti mando quella zona. Ad esempio ho true gli ack da 1 a 8 MA manca proprio il 5. Allora semplicemente mando il 5. OVVIAMENTE ricordiamoci che il timer è utilizzato anche in questo caso.

Potrebbe anche accadere di avere dei riscontri cumulativi o duplicati. Il cumulativo è quando tu mi invii 1, 2 e 3 e io rispondo solo 3, tu dai per scontato che io abbia ricevuto i precedenti.

2.2.6 La receive Window

In un meccanismo a finestra ho una.. Finestra in cui posso trasmettere. Cosa determina la suddetta? In pratica controllo la quantità di dati che posso trasmettere. Se in capo mi entrano 3 parole al minuto durante le lezioni, e i prof ne dicono 500 leggendo le slide, ne perdo un patrimonio in una lezione, stessa cosa per le reti.

Siccome in una rete è meglio evitare questo problema si implementano la ReceiveWindow e la CongestionWindow (Finestra di ricezione e congestione), e il valore che dovremo assumere sarà $W = \min\{CongWindow, RcWindow\}$, ricordando sempre la formula che la dimensione dei pacchetti da trasmettere è $\frac{W}{RTT}$

2.3 Inizio della connessione: HandShake a 3 vie

Handshake vuol dire letteralmente stretta di mano, tipo saluto, prendiamo per presupposto di avere due host che chiamiamo A e B

Questi non si conoscono, pertanto A manda a B un messaggio con

$$A \text{ scrive : } \begin{cases} SYN \\ Seq = \kappa \\ \square \end{cases}$$

$$B \text{ risponde} : \begin{cases} SYN \\ Seq = \psi \\ ACK = \kappa + 1[] \end{cases}$$

Che tradotto in termini pratici è tipo:

A: OH INIZIO A κ B: OH HO RICEVUTO $\kappa + 1$, IO SONO A ψ

$$A \text{ replica} : \begin{cases} SYN \\ ACK = \psi + 1[] \end{cases}$$

Che è traducibile in "OK HO RICEVUTO $\psi + 1$ "

2.4 Fine della connessione

$$A \text{ scrive} : \begin{cases} FIN \\ Seq = \kappa \\ [] \end{cases}$$

$$B \text{ risponde} : \begin{cases} FIN \\ ACK = \kappa + 1[] \end{cases}$$

Se però B non ha ancora finito, allora gli manda solo un ACK, mentre se ha finito anche lui, semplicemente si chiude la connessione

2.5 Congestione di rete

Avviene nel momento in cui viene inviata una quantità di pacchetti SUPERIORE a quella che normalmente può essere ricevuta, che è come quando ad Analisi venivano scritte troppe cose alla lavagna e non si riusciva a starci dietro, prima o poi avvengono perdite di dati.

Per evitare le congestioni ci sono una serie di meccanismi. Perciò iniziamo a definire una nuova quantità: MSS = Maximum segment Size, ovvero dimensione massima di un segmento.

2.5.1 AIDM: Additive Increase Mult. Decrease

Invio un messaggio, tu rispondi ok, poi ne mando due, rispondi due, poi tre e rispondi tre. Progressivamente cresce la finestra, arriverò ad un valore λ per cui non riesci a rispondere e c'è una perdita, ma può esser di due tipi:

1. Loss: Perdita
2. Timeout: Ci impiego troppo tempo a passare tutto

Il peggio tra i due è il timeout, perchè manca proprio una risposta, mentre se ho delle perdite almeno c'è comuniazione! Perciò cosa succede, appena c'è una perdita viene dimezzato il numero di dati che invio. Se la prima perdita si verifica a δ allora ripartirò da $\frac{\delta}{2}$.

Notiamo subito che questo metodo è estremamente lento, perciò c'è un secondo metodo

che fa la stessa cosa ma invece di incrementarsi di uno si incrementa esponenzialmente (1, 2, 4, 8, 16, 2^n)

Questo meccanismo esponenziale si chiama Slow Start e funziona allo stesso modo poi per quando si dimezza tutto.

Quello che abbiamo visto è come fare per trovare la quantità di dati massima che è possibile trasmettere SENZA PERDITE.

Come si gestisce il timeout? In questo caso va abbassata di tanto la finestra, perchè in questo caso non viene nemmeno ricevuto il pacchetto, scade il timeout ancor prima di aver rimandato indietro il pacchetto perciò come si agisce?

Il funzionamento è identico a quello per la perdita di pacchetti, si ragiona incrementando esponenzialmente il numero di pacchetti, poi si arriva al timeout, si dimezza, e si riparte da lì MA questa volta incrementando di 1 alla volta.

Questo incremento di un'unità per volta viene chiamata Congestion Avoidance, e (come da nome) va a risolvere le congestioni.

Ok, ma perchè non fare direttamente 1 alla volta? Perchè il tempo è una risorsa essenziale, e ragionare di pacchetto in pacchetto richiederebbe troppe risorse, semplicemente in questo modo si risparmia tempo, tutto lì.

Capitolo 3

Sistemi operativi

Un sistema operativo è un software, un programma, che agisce da intermediario tra l'utente ed il suo computer.

Molto semplicemente anche solo per scrivere questi appunti, e voi per visualizzarli stiamo usando un sistema operativo. Ma andiamo per livelli

1. Utente: Esseri umani, OPPURE anche altri computer, l'utente può essere qualcuno o qualcosa che necessita l'intervento del computer fondamentalmente.
2. Applicativi/Application programs: Sono il software applicativo, nel senso che si applicano per risolvere un problema pratico, ad esempio per dire programmi di editing foto, oppure il browser, cioè fondamentalmente estendono le funzioni fattibili dalla macchina
3. **Sistema operativo** : Controlla e gestisce l'hardware al servizio dei nostri applicativi, fa appunto come si diceva da intermediario
4. Hardware: Ci si rifà al modello di Von Neumann, CPU Ram e I/O, sempre lì si ritorna, tutte le risorse messe a disposizione dalla ferraglia per intenderci

Perchè non vogliamo che gli applicativi usino direttamente l'hardware ma ci spariamo sopra un OS che gestisca? Per due aspetti.

1. Da un lato astrae le risorse hardware, presentando una macchina estesa più facile da programmare (Files invece di blocchi di dati)
2. Dall'altro, gestisce le risorse hardware del computer, assegnandole ai programmi in maniera equa ed efficiente e controllando che questi le usino correttamente
 - Nasce dalla necessità di eseguire più programmi per più utenti sulla stessa macchina

3.1 Storicamente

Per quanto concerne l'hardware rimangono buone tutte le varie nozioni ricevute ad Architettura degli Elaboratori, lì sono state approfondite meglio da questo punto di vista (giustamente.)

Il sistema operativo oggettivamente fa in modo che le risorse dell'hardware siano gestibili per eseguire più di un software alla volta sul pc, perchè di fatto alla volta si esegue un solo programma MA ci vien data l'impressione che siano più di uno alla volta.

L'esigenza di gestire le risorse è nata assieme ai primi computer fondamentalmente, quelli a valvole termoioniche, CIOE' OH SON DELLE LAMPADINE UN PO' PARTICOLARI. Come già avrete sentito almeno 200 volte, i primi computer, aventi un milionesimo della potenza di calcolo di un nostro smartphone, eran grandi quanto una stanza, e venivano programmati direttamente staccando e attaccando i cavi in base a cosa si dovesse fare... Immaginatevi me a prendere gli appunti saltando da una parte all'altra per attaccare e staccare spine. Altro che jogging e palestra.

Solo che le valvole si guastavano, era più il tempo per ripararli che quello per usarli MA eran 20000 mila volte più veloce di fare i calcoli su C A R T A. (Computer's rules)

Dopo l'invenzione dei transistor i computer diventano più affidabili, inoltre, i transistor non si fulminano, son più rapidi, 10 volte più piccoli delle valvole. Insomma, progressivamente i computer son diventati più piccoli, veloci, e meno costosi (pensate agli smartwatch tipo MiBand per intenderci).

In seguito all'aver capito che programmare usando spine è un po' difficoltoso, tipo mezza giornata per fare $a = c + b$, per intenderci, allora si è iniziato a programmare con l'elaborazione **batch**, con programmi monitor per il caricamento ed esecuzione dei job (job control languages), (qua già si usavano le schede perforate), e qui nascevano i linguaggi ad alto livello.

Progressivamente poi c'è stato il passaggio ai circuiti integrati, infatti IBM con la magica linea 360 cerca di avere un'unica linea di computer adatta sia per ditte commerciali che per calcoli scientifici E NON SOLO perchè avevan creato dei computer che potessero essere compatibili tra loro ma differivano per la capacità di calcolo

Ci son due problemi

1. Lo stesso software doveva funzionare su tutti i computer della linea
2. Occorreva gestire le risorse della macchina in maniera efficiente in tutti gli scenari applicativi

3.2 Tecnica Multiprogrammatica

Molti programmi caricati in memoria contemporaneamente, che tradotto significa che quando un programma è impegnato nell'i/o il processore passa ad eseguirne un altro

3.3 Spooling

L'I/O viene spostato in un buffer in autonomia dal processore, perchè appunto il processore interagirà con il buffer (si fa prima) anzichè con la periferica. (Le code di stampa sono un ottimo esempio)

3.4 Time Sharing

Ad ogni persona veniva fornito un terminale ed una stampante, in cui il terminale è rimasto, era una shell su cui tendenzialmente poteva essere eseguito bash, ma non necessariamente, potrebbe essere stata qualsiasi shell.

La figura sta nel fatto che con lo stesso hardware tu avevi più terminali, che ti facevano sembrare di avere il computer solo per te ma invece era un solo computer con più terminali.

Però attenzione, poniamo di avere 10 terminali, se uno di questi fa crashare la macchina, tutti gli altri 9 crashano, e infine se le periferiche devono essere gestite in maniera che quando la periferica opera il processore non aspetta, nasce il concetto di interrupt

L'interrupt è un messaggio della periferica che letteralmente prende la cpu, la ferma e dice "Fermo, parlo io".

3.5 La varietà di esigenze

Esistono vari tipi di computer:

1. Laptop, pc, tablet: Mi rifiuto di spiegarvi cosa sono, tenete solo a mente che in teoria è massimo una persona per volta (prendetevi una qualsiasi Distro di linux, installateci l'ssh server e vedete che anche un laptop diventa server)
2. Server, mainframe, sono delle macchine con capacità di calcolo elevate (No, nel caso di un server non è obbligatorio) che rendono equa la condivisione delle risorse tra molti utenti
3. Dispositivi mobili: Avete presente i computer grandi una stanza? Ecco quelli sono CHIARAMENTE dei dispositivi TASCABILI mobili, no? Va beh, semplicemente hanno bassi consumi energetici e buona connettività.
4. Sistemi embedded: Funzionano senza (o con minimo) intervento umano, e soprattutto in tempo reale (Arduino, sì, quello è un sistema embedded per intenderci)
 - ATTENZIONE, in tempo reale significa che ci son dei tempi massimi entro cui bisogna fare le cose, e non si può sforare quei tempi, non è che lavorano necessariamente velocemente.

3.6 Composizione del Sistema Operativo

Un sistema operativo non è un singolo programma ma è composto da una serie di parti:

- Kernel: Software sempre in esecuzione che fornisce tutti i software di gestione dell'hardware (cpu ram hdd ecc)
- Programmi di sistema: E' una serie di software di gestione di processi jobs, interfacce grafiche, cose così

- Middleware: Servizi di alto livello per programmare applicazioni (Framework grafici, sonori, etc)

Capitolo 4

I processi

- Cos'è un processo
- Come vengono schedulati?
- Che operazioni si possono effettuare sui processi?
- IPC (Memoria condivisa, message passing)
- Comunicazione in sistemi client-server

I più attuali OS sono in grado di eseguire più software in concorrenza, allo stesso momento, per intenderci. Ma iniziamo a definire meglio questo software, che da quando va in esecuzione prenderà il nome di **processo**.

Come si compone un processo?


- Stato dei registri del processore, compreso il PC
- Codice del programma (Segmento text)
Sarebbe quello che buttavamo nel text di Assembly su QTSpim, cioè l'insieme di istruzioni che vengono eseguite
- Stack delle chiamate, contenente parametri, variabili locali ed il return address
- La **Data Section** contiene le variabili globali, quelle statiche che vengono allocate prima dell'esecuzione dei programmi
- L'heap, che contiene la memoria allocata dinamicamente durante l'esecuzione, quella che in Java si usava quando venivano istanziati gli oggetti, o i vettori.
- Altre risorse acquisite dall'OS, come socket oppure file contenuti sull'OS.

ATTENZIONE: Finora si è sempre menzionato il concetto di programma, sappiamo cos'è, no? Un programma è un insieme finito di istruzioni, fondamentalmente, ma quando queste vengono eseguite diventano un **PROCESSO**.

Il file eseguibile è un programma, non un processo, mentre l'applicativo che state usando ora per leggere queste righe (Perché son certo che non ve le stamperete su carta come me

;) è un processo che avete in memoria da qualche parte.

Come è organizzata la memoria di un processo?



Tra stack ed heap perchè ci sono i puntini? E le frecce? Stack ed heap condividono lo stesso spazio di memoria, MA cambia il verso di allocazione dei dati.

Lo stack inizia dall'ultima locazione di memoria, e prosegue verso il basso, mentre l'heap inizia da dopo il segmento data. Per cui siccome condividono memoria, nel caso se ne avesse poca, bisognerebbe prestare bene attenzione a come questa viene usata.

4.1 Gli stati di un processo

I processi sono in esecuzione, fin qui ci siamo, ma dove? Sull'OS. Pertanto, la gestione dei processi è tutta opera dell'OS, e questa gestione fa la differenza tra un OS valido ed uno meno valido, insieme ad altri fattori.

Gli stati di un processo sono:

- New: Il processo è in attesa di essere ammesso (admitted) dallo scheduler
- Ready: Il processo è stato schedulato ed è pronto per essere eseguito
- Running: Il processo entra in fase di esecuzione
- Waiting: Il processo è in attesa di ricevere un valore, un dato, qualsiasi cosa, in generale in attesa di un evento (L'I/O è la causa).
- Terminated: Il processo ha finito la sua esecuzione, ha fatto quello che doveva fare MA ancora non è killato.

Il sistema operativo può anche interrompere un processo e rimmetterlo allo stato di ready, con un interrupt, cioè scade il tempo dedicato a quel processo, passa agli altri che ci son dopo.

Dal punto di vista della sequenza:

$$New \implies Ready \implies Running \implies Terminated$$

Con gli accorgimenti poi su Waiting e ritorno a ready per gli interrupt.

4.2 Process Control Block (PCB)

Ha anche il nome di Task Control Block, ma PCB ci tornerà migliore.

Cos'è?

E' una struttura per i dati del sistema operativo in grado di riconoscere, identificare e tenere traccia di un processo. Cosa contiene?

- Process State: Indica lo stato (Ready running blabla)
- Process Number (PID), identifica il processo (Chi è)
- Program counter: Contenuto del registro **Dell'istruzione successiva**
- Registers: Il contenuto dei registri
- Informazioni di Scheduling: Priorità, puntatori a code di scheduling
- Informazioni relative alla gestione della memoria (quella allocata al processo)
- Lista di file aperti
- Lista dei processi figlio

4.3 Threads

Finora si è considerato il processo come un unico flusso di roba sequenziale, ma in realtà è possibile avere più program counter per lo stesso processo, cioè più istruzioni possono essere eseguite assieme, e più percorsi di esecuzione.

Questi flussi di esecuzione prendono proprio il nome di Thread, ed in questo caso il **PCB** Conterrà informazioni ulteriori per ogni Thread

4.4 Scheduling dei processi

Schedulare significa scegliere il prossimo processo da eseguire tra quelli che son lì pronti, quelli che son ready, ma perchè? Perchè l'obiettivo è quello di far lavorare al massimo la cpu, sfruttare al meglio le risorse che si hanno.

Lo scheduler analizza tutti i PCB, in delle vere e proprie code. Ci sono due code, una ready queue in cui ci son tutti i processi in stato ready, e poi c'è una wait (in realtà son più di una) che è una coda per i processi in stato di waiting. Inutile dire che un processo rimbalza da una parte all'altra costantemente.

Ecco un esempio di cosa potrebbe accadere -> [Esempio di Banana Joe](#)

Quando il sistema operativo passa da un processo all'altro esegue un cambio di contesto

4.5 La commutazione del contesto

Il sistema operativo a tutti gli effetti congela il processo attuale per andare poi a eseguire un altro che in precedenza era stato congelato. Cosa accade quando si congela un processo? Semplicemente si vanno a copiare tutti i dettagli del PCB, vengono sovrascritti con i più aggiornati.

Un processo congelato si dice processo in "idle", che è una condizione che viene spesso usata quando si menziona la durata delle batterie sui vari device.

Esempio "Il mio telefono in idle non consuma niente, ma basta aprire app come il blocco note, ed esplode" cit. utente medio di Windows Phone. Concettualmente, in idle è letteralmente come quando noi usiamo il concetto del "senza far niente".

Quando prima si diceva di "far lavorare il processore" si intendeva che non si deve mai avere del tempo morto, perchè ognuno di questi momenti morti, è perdita di tempo, il processore deve lavorare il più possibile.

C'è un problema, se io tengo il processore però a manetta, la batteria ne risentirà moltissimo. Di conseguenza con i dispositivi mobili si ragionò al contrario, ovvero, meno lavora la cpu, più risparmio.

4.6 Background e Foreground

I processi attivi e visibili su schermo si dicono in Foreground, per intenderci una volta chiusi, ciao, fine, non rimangono in ram, mentre il background parla da sè, implementato da Android (ce lo ricordiamo bene com'era veloce agli inizi, no?), e importato anche da Apple con iOS4.

(Parlo di dispositivi mobile sui pc e mac c'era da sempre). Oggi non si hanno problemi, potete tenere aperte assieme Whatsapp e Telegram. Arriveremo un giorno ad avere abbastanza ram da tenere aperta Facebook Whatsapp e il blocco note.

Teniamo a mente che l'OS fornisce delle funzionalità per eseguire processi, tipo con le API (E PI AI si legge) che sono delle librerie, che ha anche Google, che fa da tramite, da interfaccia,

4.7 Creazione dei processi

Dato un processo, se esso avrà un figlio, quest'ultimo eredita risorse? Non c'è una regola, dipende da cosa decide il programmatore di turno, potrebbe ereditarne solo alcune, tutte, una sia e una no, dipende.

Nella filosofia Unix, se un processo padre crea un figlio, in realtà esso sarà un duplicato del padre, ATTENZIONE è una copia, non è la stessa cosa, non è il padre, è un doppione. (Il motivo nasce dalla storia di Unix, che è nato con la filosofia Kiss, keep it simple stupid, deve funzionare e fare il suo mestiere bene.).

In un sistema Unix, un padre può interagire in 3 modi con il proprio figlio:

1. Fork(): Crea la copia precisa del padre ed avrà pid=0 (rispetto al padre eh)
2. Exec(): Esegue suo figlio, in tutti i sensi, perchè lo ucciderà anche se necessario
3. Wait(): Quando lancia il figlio, si mette in attesa che quest'ultimo finisca

Capitolo 5

Thread e concorrenza

Finora si è parlato di processi che NON sono concorrenti, o meglio, che vengono eseguiti singolarmente, ora si parlerà di Thread, si capirà la differenza tra un processo ed un Thread, capiremo quali sono vantaggi e svantaggi

Inoltre tratteremo il Threading implicito (pools, fork-join, etc.), descrivere come questo viene rappresentato il Thread dai vari OS E vedremo come si progettano applicazioni aventi Thread, usando le API pthreads, Java e Windows

5.1 Perché utilizzare Threads?

I motivi sono molteplici:

1. E' un'estensione semplice da realizzare, ed i processi risultano più difficili da creare, nel senso: Un Thread ha solo la sua cpu virtuale, mentre un processo ha molta più roba da generare.
 - Attenzione: Le applicazioni concorrenti ed i Thread non sono la stessa cosa
 - I Thread migliorano l'efficienza di creazione del flusso di un processo, che risultava effettivamente troppo costosa in termini di risorse
2. Sfruttamento dei core multipli, nelle cpu a più cores
3. Gestione di compiti simili tra loro, se devo fare la stessa operazione su λ dati, posso aprire λ Threads, per esempio!
4. Semplifica il codice, ma in generale si aumenta l'efficienza
5. Per intenderci, qualsiasi kernel usa più Threads

Per intenderci: Avete presente il vostro telefono? Quando pigiate sullo schermo, a rilevare il vostro tocco c'è un Thread attivo, e allo stesso tempo, cosa fa visualizzare le nuove notifiche mentre giocate a qualcosa mentre siete in bagno? Esatto, una serie di Thread, ognuno con il suo scopo!

In java finora abbiamo SEMPRE sviluppato programmi monoThread, nel senso, una cosa alla volta. Nel senso, mentre aspetta che noi inseriamo il carattere da tastiera, il nostro programma non poteva fare altro, con i Thread è possibile implementare una roba del genere.

5.2 Parallelismo e concorrenza

- **Concorrenza:** Si verifica quando hai κ operazioni di un processo e λ di un altro, quello che succede è che fai un po' uno e un po' l'altro. Avete presente preparare 5 esami assieme? Esatto non ne prepariamo nessuno
- **Parallelismo:** Hai due processori separati ed indipendenti, quindi i tuoi processi saranno separati o meglio, distribuiti su questi ultimi, e.. No, non avremo mai due cervelli, 4 mani e 48 ore di studio al giorno, sad.

A questo punto va compreso in fase di progettazione l'importanza dei vari task da eseguire per ogni core, e occorre bilanciare il lavoro in modo da avere moli di lavoro confrontabili

Mi spiego peggio: Suddividendo in modo bilanciato il lavoro allora anche i dati concettualmente si ha una massimizzazione dell'accesso parallelo, MA il vero motivo per cui sviluppare Thread sta nel Testing e nel Debugging

Perchè? Perchè avendo più Thread, se per ipotesi crasha il Thread del touch del telefono, bene, avremo un errore preciso da quel Thread, sappiamo dove intervenire, soprattutto perchè si ha una certa riproducibilità da questo punto di vista.

5.3 Chiarezza sul parallelismo

Il parallelismo non è applicabile solo alle task che eseguiamo, ma anche ai dati su cui esse vanno a lavorare.

1. **Parallelismo dei dati:** Si verifica quando ho operazioni tutte uguali, mi basta dividere i dati in tanti pezzi, ed ogni core opera su uno di questi pezzi
2. Questo invece consiste nel dividere un intero processo, in una serie di core, quindi tutti lavorano sullo stesso processo

5.4 Legge di Ambdahl

Ma se noi aggiungiamo un processore, ci guadagniamo? quanto?


$$\text{Incremento velocit} \leq \frac{1}{S + \frac{1-S}{N}}$$

S sarebbe la porzione di programma che va realizzata sequenzialmente, mentre N invece è il numero di core

Facciamo un esempio Se il 75% dell'applicazione è parallelizzabile ($S = 25\%$)

- Se ho 2 core 1,16 volte più veloce del single core
- Se ho 4 core 2,28 volte più veloce del single core

Siccome si capisce effettivamente poco allego l'immagine riportata a lezione, con un grafico che aiuta a capire meglio l'andamento.



Idealmente l'incremento dovrebbe essere esponenziale, ma in realtà si dimostra che progressivamente si appiattiscono le prestazioni ed il rapporto tra costo e prestazione diventa meno conveniente.

Quindi, si dimostra che più di 4/8 core PER ORA siano più che sufficienti per quelle che sono le operazioni che facciamo noi oggi.

5.5 Modelli di supporto per Threading

- Thread livello utente: Ci sono una serie di librerie in grado di gestire i thread nello spazio dedicato ai processi utente. (Threads di tutto ciò che non è l'OS, per semplificare)
- Thread livello Kernel: Tutto ciò che è riguardante l'OS, ad esempio il Thread di gestione dell'orologio, oppure quello che serve per anche solo la barra applicazioni.

Inizialmente il kernel era monoThread, e tutto ciò che era multiThread era nell'userspace, quindi questo è praticamente pseudoparallelismo, perchè se un Thread fa I/O allora tutti gli altri staranno in attesa, non è in grado di sfruttare più core.

5.5.1 Modello 1 a 1

Per ogni Thread del kernel esiste un Thread nell'userspace, il che significa che si può sfruttare il parallelismo MA attenzione.

Se ho un server avente più utenze, se ogni volta tipo 100 utenti mi aprono 10 Thread a testa, il kernel mi va a 1000 Thread. Per ipotesi si è posto un limite ai Thread che puoi aprire

5.5.2 Modello molti a molti

Si hanno κ Thread del kernel \times λ Thread utente, in cui $\kappa < \lambda$

5.6 POSIX PThreads

Non è un'implementazione ma una specifica (uno standard praticamente) che consente a sistemi operativi Unix based o anche agli Unix like di poter implementare dei Thread. (In c c'è la libreria pthread.h che serve a questo)

Su Windows c'è windows.h che consente di avere i Windows Thread, dovrebbero funzionare anche lì ma in modo più... Minuzioso (No, non dirò quella parola.).

Windows per ogni Thread crea un handle, che va creato e chiuso dal padre del Thread.

5.7 Thread in Java

Si possono sviluppare in due modi

- Estendendo la classe Thread e creando il metodo run
- Implementando l'interfaccia Runnable e anche lì creando il metodo run
- Da qui basta instanziare un oggetto di questa vostra classe, e fare nomeOggetto.start(); ed il Thread partirà.

5.8 Threading implicito

Delega tutto ciò che è la creazione e gestione dei Thread ai compilatori ed alle librerie, perchè così gli sviluppatori non devono preoccuparsi di stare a gestire appunto fattori come chiusura e manutenzione del Thread aperto

5.9 Thread pools

All'avvio viene creato un buon numero di Thread, organizzati in un gruppo che semplicemente aspettano di rispondere ad una richiesta, ed in questo modo:

- Si accelerano i tempi

- Il numero di Thread contemporaneamente aperti è limitato dalla dimensione del pool
- Separa il task dalla meccanica della sua creazione, avendo o meglio, permettendo diverse strategie di esecuzione, con uno scheduling temporale nella mia applicazione.

Nel POSIX queste meccaniche non ci sono, mentre ci sono su Windows e Java sono previste

5.10 Fork-join

Vi ricordate il merge sort che divideva in due l'array, no? Ecco, dividiamo i due array, avviamo un thread per una metà, ed un altro per l'altra metà, con poi il "combine" vengono riunite.

5.11 Problematiche possibile

Una fork dovrebbe duplicare solo il thread chiamante o tutti i thread in assoluto? Ecco, il magico mondo UNIX utilizza due tipi di fork per risolvere questa cosa

L'exec invece di solito sostituisce tutti i thread del processo in esecuzione

5.12 Signal Handler

Un segnale è un meccanismo nei sistemi Unix ed Unix like per notificare un evento ad un processo.

Banalmente sono degli interrupt MA lato utente. Ci sono tante scuole di pensiero, su Unix se hai un segnale verso un processo, allora l'handler viene eseguito una sola volta, quindi viene eseguito ad un solo thread. Sotto Unix c'è un modo per fare in modo che un Thread rifiuti un determinato insieme di segnali

Un segnale potrebbe essere ctrl+c, che non copia eh, termina l'esecuzione del programma corrente su terminale .

Su Windows non ci sono i segnali ma le APC, che son comunque simili, praticamente sono delle chiamate di procedura, che sono associate al thread, non al processo.

5.13 Cancellazione del thread

E' possibile fare in modo che un Thread termini l'esecuzione PRIMA che abbia effettivamente finito di fare quel che deve fare? Si in due modi

- Cancellazione asincrona: Il thread viene terminato di cattiveria, tipo come agli esami a tempo fatti su pc, quando finisce, finisce.

- Cancellazione differita: Se thread A vuole terminare B allora B gli dice "Spetta n'attimo", e appena finisce si chiude, come quei 5 minuti in più che a volte si riescono a chiedere per finire di scrivere nome cognome e data in un esame.. E matricola

Capitolo 6

Scheduling della CPU

6.1 Cos'è lo scheduling?

Schedulare significa stabilire l'ordine e il momento dell'esecuzione delle istruzioni impartite a un elaboratore: Cioè per esempio, anche la stampa di un file.

Osservazione: Non esiste un solo metodo per schedulare i processi, infatti esistono svariati algoritmi, addirittura Linux nel corso degli anni ha cambiato 3 volte i suoi algoritmi

Esiste uno scheduling perfetto? All'atto pratico no, nel senso, si deve simulare un ipotetico carico medio di lavoro, per capire come fare funzionare al meglio le risorse, ma non esiste l'algoritmo perfetto. SE PERO' conoscessimo perfettamente il carico di lavoro, ALLORA chiaramente si può distribuire perfettamente il carico. (Spoiler: No, non si può conoscere in modo perfetto.)

6.2 Concetti fondamentali

L'obiettivo è sempre lo stesso, ovvero massimizzare l'uso della cpu, ed infatti gli algoritmi di scheduling sfruttano il fatto che di norma l'esecuzione di un processo è una serie di

- Burst della CPU: Sequenza di operazioni della CPU
- Burst dell'I/O: Attesa del completamento dell'operazione di I/O

Sapersi gestire i burst della CPU è essenziale. Ma quanto dura un burst? In programmi normali è generalmente c'è un alto numero di burst brevi ed un basso numero di burst lunghi.

6.3 Scheduler della CPU (A breve termine)

Seleziona un processo tra quelli nella ready queue ed alloca un intero core ad esso, ma in che modo?

Modo nonPreemptive o cooperativo, senza preselezione

1. Quando un processo passa da running a waiting
2. Quando un processo passa da running a ready
3. Quando un processo passa da waiting a ready
4. Quando un processo termina

Questo metodo è stato praticamente mollato da Windows 95, però non è del tutto così. Nel senso, Windows 95 eseguiva sia software a 32 che 16 bit, e quindi quando eseguiva quelli a 16 utilizzava il metodo nonPreemptive.

Modo preemptive Si applica per rispondere e risolvere le seguenti domande

1. E se due processi condividono dati?
2. E se un processo esegue codice in modalità kernel?
3. E se un processo sta eseguendo un gestore degli interrupt?
4. (E se sti gran **Censura** ;))

6.4 Dispatcher

Si occupa di passare il controllo della CPU al processo scelto dallo scheduler, e impiega del tempo, infatti esiste un dispatch lag, o anche latenza di dispatch, che in pratica si genera dalle seguenti operazioni:

1. Effetta il cambio di contesto
2. Passa in modalità utente
3. Salta nel punto corretto del programma del processo selezionato, cioè alla fine dove era stato interrotto

6.5 Gli algoritmi di scheduling

Prima di capire se un algoritmo è migliore di un altro abbiamo da tenere in considerazione ci sono una serie di criteri da tenere in considerazione, cioè

1. Utilizzo della CPU (In percentuale), quanto tengo impegnata la cpu ad eseguire codice utente (Di solito si va dal 40 al 90%)
2. Throughput: Numero di processi che completano l'esecuzione in una determinata unità di tempo (ad esempio $\lambda \frac{Processi}{s}$)
3. Tempo di completamento: Tempo che serve per finire l'esecuzione di un processo (dipende da troppi fattori, tra l'altro c'è pure l'attesa I/O, cioè immaginatevi un programma che fa un input e l'utente sta lì fermo per 3 ore... Ed il programma finisce con `print("ciao")`)

4. Tempo di attesa: Tempo in cui il processo sta nella ready queue
5. Tempo di risposta: Negli ambienti time-sharing (quelli in cui si ha un solo core per intenderci) è il tempo che passa da quando arriva una richiesta al processo a quando effettivamente si arriva alla prima risposta SENZA l'emissione di questa nell'output.

6.5.1 Scheduling in ordine d'arrivo

FCFS (First come, first served), il primo che arriva è il primo che se ne va, come le code, sì, esatto. Proprio per questo è anche semplice da implementare, è una coda.. La sappiamo fare MA ha uno svantaggio, il tempo medio di attesa (dipendente da quanti processi si hanno) potrebbe essere lungo.

6.5.2 Scheduling per brevità

SJF (Shortest job first), colui che ha il burst più piccino viene preso per primo, in questo modo diminuisce il tempo di attesa medio.. Ok ma, come fai a sapere quanto sarà lungo un burst prima di eseguirlo? Come fai a capire quanti anni ci avrai impiegato per laurearti PRIMA di avere fatto l'iscrizione in uni? Esatto, minimo 5 (per la triennale).

Si ma quindi è applicabile? Allora, fondamentalmente è utopistico ma applicabile in qualche strano modo, in cui si fanno delle previsioni. Per capire meglio si fa una stima di durata del burst ragionando sui seguenti dati:

1. T_n = durata dell'n-esimo burst
2. Scegliamo un valore $\alpha \in (0, 1)$
3. $T_{n+1} = \alpha \cdot T_k + (1 - \alpha)T_k$
4. La mia media esponenziale (data da) T_{n+1}

C'è anche una versione preemptive, che si chiama shortest-remaining-time-first, non è buona come la SJF ma ci si avvicina comunque.

E $L'\alpha$? E' un valore che si ottiene confrontando la stima del burst precedente con l'effettivo vero burst precedente. Generalmente si mette $= 0,5$ cioè random va o uno o l'altro. Se fosse 1 o 0:

- 1: Non conta il burst precedente
- 0: Conta solo il burst precedente

In questo caso teniamo non proprio in considerazione qual è il processo che impiega effettivamente meno, ma quello a cui rimane meno roba da fare

6.5.3 Scheduling Circolare

E' il Round Robin, di solito viene combinato ad altri algoritmi, ma fondamentalmente è quello più usato, è il classico algoritmo preemptive.

Come funziona? Ogni processo ha una quantità fissata di tempo che sta tra i 10 ed i 100 millisecondi, ed è praticamente come distribuire le carte a Poker.

So con certezza qual è il limite superiore che un processo attenderà, se ci sono n processi nella ready queue il quanto temporale è q , ed ogni processo otterrà $\frac{1}{n}$ di tempo di CPU. E nessuno di questi aspetterà più di $q(n-1)$.

Che performance ha?

- Se q è alto, tende al FCFS
- Se q è basso, ottieni

Rispetto a SJF ha un tempo medio più alto dal punto di vista del completamento ma allo stesso tempo riduce le latenze, ATTENZIONE, migliorando q non si implica un miglioramento del tempo di completamento.

6.5.4 Scheduling con Priorità

Ogni processo ha un numero intero che rappresenta la sua priorità, più è basso il valore, più questo ha priorità appunto. Può pure essere preemptive, ed ha priorità sui nonPreemptive

E se due processi hanno stessa proprietà? A quel punto qualsiasi strategia va bene, dipende dal processo (Linux questo lo gestisce bene). Viene eseguito il processo con priorità più alta per primo chiaramente

Sì, ma se ho un processo di bassa priorità? Potrebbe pure non essere mai schedato, potrebbe morire per **Starvation**, non viene mai eseguito

Soluzione? Invecchiamento (Aging), ossia diminuzione progressiva del valore di priorità (aumento progressivo della priorità)

CALMI, Precisiamo meglio questa cosa: IL VALORE che si associa alla priorità più è alto, più il processo PERDE priorità. Esempio: Priorità 0 viene eseguita PRIMA di priorità 1.

Capitolo 7

Livello Data-Link (SECONDO PARZIALE)

Per questo argomento vi consiglio di guardarvi [questo sito](#):

Per definizione: Il livello data-link riceve dati dal livello fisico, ed offre servizio al livello network. Il livello 2 (Data Link Layer) si occupa di gestire il collegamento da un pc all'altro appartenenti alla stessa LAN (Local Area Network) e' un sistema di comunicazione che permette ad apparecchiature indipendenti di comunicare tra loro, entro un' area delimitata, utilizzando un canale fisico a velocita' elevata e con basso tasso d'errore.

Altra funzione principale di questo livello e' quella di recuperare gli errori trasmissivi: di solito questo avviene mediante tecniche di ritrasmissione automatica dei dati che sono stati ricevuti corrotti. Il protocollo Ethernet appartiene a questo livello.

7.1 Media Access Control

Il concetto di MAC si introduce ragionando sul concetto del "Mezzo condiviso", introduciamo inoltre l'uso dello Switch, ovvero un dispositivo che consente di avere più macchine che sfruttino lo stesso mezzo.

7.2 Switch e Hub

- L'hub quando riceve dei dati automaticamente li invia in broadcast a tutti quanti i nodi connessi
- Lo switch invece serve per fare in modo che il pacchetto parta da un mittente preciso ed arrivi ad un destinatario (connessi allo switch chiaramente)

Ora, anche in questo caso siccome a lezione si ha poca chiarezza, lascerò lo stesso il materiale direttamente proveniente dalle superiori. AHAHAHAHAH.

7.3 Framing

Il secondo livello forma dei pacchetti dati, detti frame o trama, da far viaggiare lungo la dorsale di comunicazione. Il frame e' l'unita' dati fondamentale di questo livello. Il

livello DataLink incapsula il pacchetto proveniente dallo strato superiore (livello 3) in un nuovo pacchetto detto frame (o trama) al quale aggiunge un header (intestazione) e un tail (coda).

Ethernet, Token Ring, FDDI, IEEE 802.11 (WLAN), ATM, TCP/IP's Serial Link Interface Protocol (SLIP) e Point-To-Point Protocol (PPP) sono alcune tecnologie e protocolli associati al livello 2. Anche il protocollo ARP che permette di conoscere l'indirizzo fisico di una scheda di rete corrispondente ad un indirizzo IP, appartiene a questo livello.

7.4 Correzione degli errori

Sapendo che ci sia un flusso di dati di qualsiasi tipo, è normale che ci sia la presenza di errori, che dipendono da molteplici fattori. Per intenderci il collegamento via radio genera molti più errori rispetto al cavo.

Come si rilevano? Esistono diversi modi per poter andare a capire se ci son stati errori

7.4.1 CRC (Codici di ridondanza ciclica)

In invio: Hai il messaggio e il polinomio generatore. Al messaggio aggiungi tanti zeri quanto è il grado del polinomio generatore. Poi fai lo XOR tra il messaggio finale e il polinomio... Arrivi alla fine, e al messaggio iniziale, aggiungi il risultato della divisione, con tante cifre quanto il grado del polinomio..

In ricezione: Dividi semplicemente, con lo XOR, il messaggio per il polinomio e se trovi 0 è tutto OK, altrimenti ci sono stati degli errori di trasmissione.

Il polinomio: può essere scritto in due forme, in cifre binarie o con le potenze.. Se è in binario è semplicemente una sequenza (tipo 1011, 1001 ecc.). Se è con le potenze (può essere una cosa del genere " $G(x)=x^3 + x + x^0$ ", " $G(x)=x^3 + x^0$ " ecc.) lo trasformi in binario (rispettivamente 1011, 1001)

7.5 L'indirizzo MAC

E' un indirizzo composto da 48 bit (6 byte) ASSOCIATO ALLA SCHEDA DI RETE, in pratica NON può cambiare, è univoco, ogni schedina ha il suo MAC address, non c'è alcuna relazione tra un MAC address e l'altro, non si possono aggregare, nè localizzazioni geografiche. L'unico modo è scavare l'indirizzo MAC localmente.

All'atto pratico: Se ho lo stesso MAC in Italia ed uno in America, a meno che son proprio stronzo, non saranno mai praticamente nella stessa rete.

AH SI' poi è chiaro che essendo un numerello scritto in un firmware, allora si può cambiare con qualche arcano particolare ;)

7.6 Gli accessi concorrenti:

7.6.1 Token Ring:

Si applica su reti a forma di anello, ovvero reti circolari in cui per ogni nodo c'è un collegamento a precedente e successivo.

La particolarità di queste reti sta nel fatto che lo scambio di informazioni è regolato dalla trasmissione di uno dei nodi della rete di un particolare messaggio (chiamato token) che stabilisce quale nodo abbia “diritto di parola” e quale nodo debba ricevere il pacchetto dati (o i pacchetti dati) che viaggiano in simbiosi con il token stesso.

Come funziona Token Ring: All'interno di una LAN organizzata nel modo appena descritto, ogni nodo avrà “diritto di parola” sequenzialmente e solo in quel momento sarà autorizzato a inviare i suoi pacchetti dati verso il nodo mittente.

In modo più specifico: Pacchetti dati vuoti (detti frame) circolano all'interno della Token ring in maniera continua. Quando un computer dovrà inviare un messaggio, crea il token contenente i dati del nodo di destinazione e lo “lega” ai pacchetti da inviare. Arrivato il suo turno passa token e informazioni al computer successivo, che scansiona il token e verifica quale siano i dati scritti al suo interno;

nel caso in cui non sia lui il destinatario della comunicazione, passa pacchetti dati e token al nodo successivo. Questa operazione si ripete per ogni nodo della LAN, sino a quando il messaggio non raggiunge il suo destinatario.

A questo punto il computer copierà i pacchetti dati e sovrascriverà le informazioni presenti nel token, azzerandolo di fatto. Quando il token avrà completato il proprio giro, il nodo-mittente scansionerà il “testimone”,

verificherà che le informazioni contenute al suo interno sono state sovrascritte ed eliminerà i pacchetti dati presenti all'interno del messaggio. All'interno della LAN ad anello tornerà a circolare un frame vuoto.

7.6.2 Slotted Aloha:

La chiave sta nel fatto di aver individuato il conflitto, e qui si capisce

7.7 Slotted Aloha

7.8 CSMA/CD

7.9 Backoff Esponenziale

7.10 802.3

Capitolo 8

VLAN

Per definizione una VLAN è una rete locale (LAN) però virtuale.

A che serve? Allora, se abbiamo presente cos'è uno switch, sappiamo che è possibile connettere tra loro più host assieme, ma la VLAN estende questa possibilità ad un livello superiore. Nel senso che ti consente di creare diversi domini di **broadcast**

Cioè? Prendi un client che invia una richiesta per sapere il MAC address di un determinato indirizzo, come fa? Niente invia un messaggio a tutti, e gli arriverà la risposta di quello corrispondente.

Bene, ora però immaginati una rete turbogigante di dimensioni abnormi, un messaggio in broadcast dà molto fastidio. PERTANTO, ciò che accade è che grazie alla VLAN tu puoi evitare questa cosa, perchè le richieste di broadcast vengono limitate solo a quella VLAN.

Osservazione: Un aspetto da rimarcare è che le VLAN possono essere estese anche oltre i limiti fisici del singolo switch. Supponendo di avere una rete che si sviluppa su più piani, si può usare il trunking per collegare più switch tra di loro quindi sfruttare il protocollo 802.1Q, uno standard con cui l'hardware provvede ad aggiungere - in ciascun frame Ethernet - le informazioni sulla VLAN di appartenenza dei dati in transito (è prevista una tag aggiuntiva da 4 byte). Così facendo dispositivi fisicamente lontani l'uno dall'altro possano appartenere alla medesima VLAN.

Inoltre si hanno i seguenti vantaggi:

- Si possono isolare determinati gruppi di dispositivi, tipo un gruppo di stampanti o cose simili
 - Perchè mai? Perchè ci sono alcuni dispositivi che non ha senso che possano accedere ad altri
- Si migliora la gestione del traffico, grazie al QoS che riesce a prioritizzare il traffico (ci son delle politiche). In pratica puoi limitare la banda per un determinato host.

Avete presente le mamme che guardano i video su Whatsapp con il volume a 12000 db? Ecco, potrete disattivarle il wifi

- Si possono creare reti più scalabili, nel senso che espanderle risulta effettivamente più semplice
- Per creare una sottorete non devi stare a comprarti un nuovo switch, puoi fartela pure con uno switch e basta (Sì, la poraccitudine regna sovrana)

Capitolo 9

Wireless

Neanche a dirlo, si sta parlando di un metodo di collegamento che sfrutta le onde radio invece che il mezzo fisico (Il cavo), non si ha un accesso più "fisso" ma appunto.

Neanche a dirlo: La presenza di errori per quanto riguarda un collegamento radio è molto più elevata rispetto al mezzo fisico, perciò è necessario sviluppare dei metodi di prevenzione e correzione errori.

Concettualmente: in un collegamento fisico io so esattamente da dove arriva un segnale, nel wireless invece ce ne son tanti di segnali che viaggiano assieme. Per ora differenziamoci i problemi che si devono affrontare.

1. **Il collegamento radio stesso:** Quando si parla di un accesso wifi si ha più questo problema rispetto agli altri.
2. **Localizzazione del dispositivo**
3. **Handover**

Un collegamento con rete cellulare (3/4/5/10 G+) si hanno tutti e tre questi problemi insieme.

Il collegamento radio: Per questo ho allegato un file pdf che sarebbe contenente appunti presi in quarta superiore, non si sa mai, può sempre servire.

Tendenzialmente l'acqua è un attenuatore dei segnali, questo spiega perchè un albero (soprattutto le sue foglie) sia un attenuatore del segnale. Molti impianti fatti in inverno (con alberi senza foglie) poi smettono di funzionare per via dell'acqua presente nelle foglie. Il concetto è che un segnale radio è molto complesso (Realizzabile, chiaro), ma complesso.

Si sono fissate 3 bande di frequenza standard (recentemente) assegnate per la nuova 5G (in Italia)

- 800 Mhz
- 3,5 Ghz

- 28 Ghz

Cosa si intende per frequenza assegnata? Una frequenza o è libera o assegnata in concessione, poichè le frequenze **NON** possono esser vendute **MA** solo date in concessione. Sono **SEMPRE** proprietà dello stato. C'è una regolamentazione mondiale ma a noi ci importa una bellissima **Censura**.

per "Frequenza libera" non si intende che puoi fare quello che vuoi a quella frequenza **MA** che (con apparati che siano regolari) puoi lavorarci.

Cosa significa? Non hai garanzie di avere una trasmissione libera da problemi, oggi c'è il Wifi 5ghz che comunque è una banda più libera di quella a 2,4. Tra l'altro il 5 Ghz tende ad attenuarsi di più, in questo caso è un vantaggio.

Precisazione: Quando c'è una frequenza assegnata in concessione, in pratica si hanno anche delle garanzie dallo stato per quella frequenza, e nel momento in cui si assegna una determinata frequenza, (ipotesi al 4G), non è che tutti gli operatori vanno a quella frequenza **MA** stanno attorno a quei valori.

Esempio: A TIM assegno da 780 a 800 Mhz, a Wind da 800 a 820, e così via, in base al tuo operatore verrà usata una determinata frequenza.

Data un'antenna di una determinata dimensione questa dipende da $\lambda = \frac{C}{f}$ Con f che è la frequenza e C che è... Non ricordo, devo cercarmelo, mandatemi un issue e lo risolvo.

9.1 Antenna MiMo

Acronimo di Multiple in Multiple out, la tecnologia MiMo sfrutta il multipath, un fenomeno naturale e molto conosciuto delle onde radio. Questa proprietà permette di aumentare la velocità di trasmissione senza che sia necessario aumentare la larghezza della banda di trasmissione:

il segnale sarà inviato da diverse sorgenti (antenne di trasmissione) e, grazie a "giochi di sponda" con muri, mobili e altri oggetti presenti nell'ambiente, raggiungerà l'antenna ricevente seguendo percorsi multipli in tempi leggermente diversi, creando, così diversi flussi dati simultanei in grado di trasportare più informazioni rispetto ad un singolo flusso "standard".

Il vantaggio è che puoi trasmettere o a velocità. Uno dei maggiori problemi che affligge i router Wi-Fi è il cosiddetto collo di bottiglia: in alcuni casi può accadere che in dati in ingresso e in uscita siano superiori al flusso che il dispositivo può gestire e ne risulta una congestione e un rallentamento generale delle prestazioni.

Nel corso degli anni sono stati progettati diversi metodi e tecnologie per tentare quanto meno di mitigare la situazione. Tra queste, la più efficace è senza dubbio la tecnologia MiMo, che permette di aumentare la velocità e il flusso dei dati in viaggio attraverso una connessione wireless.

9.2 Bit Error Rate

E' un valore, un rateo di errori che ci possono essere, approssimativamente è

$$Ber < 10^{-12}$$

9.3 SNR (Rapporto tra segnale e rumore)

In base a questo rapporto, cambia la qualità del mio segnale, la prima cosa che devo fare è ragionare su come funzionerà il mio canale, nel senso in base al suo livello di errori. Minore è il tasso di errore e più la conversazione ha qualità, viceversa.

9.4 Modulazione e codifica dei segnali

Esempio molto semplice: Devo trasmettere dei bit, ho un bit ad 1 che è un segnale positivo, e il bit a 0 che invece è a segnale o negativo o spento. Ipotizziamo una stringa di 100100011. Questo segnale circa usa una frequenza che è la metà del bitrate. (Teniamo conto che è figlio di una sinusoide questo segnale digitale).

Si può essere più aggressivi? Perchè trasmettere solo un livello? Perchè non tra-

smettere 4 livelli? Cioè perchè trasmettere solo 0 o 1 invece di $\begin{cases} 00 \\ 01 \\ 10 \\ 11 \end{cases}$?Cioè in pratica si

raggruppano i bit di prima e diventano 11-10-00-11-01 ... ok, perchè non usarne 3? 10? 256? Sarebbe bello il mondo se da qualche parte non ci arriva l'inculata. Infatti se noi aumentiamo la profondità di codifica, avviene che il segnale diventa più vulnerabile al rumore. Quindi una determinata frequenza magari vien codificata con il valore subito successivo o precedente.

Perciò modulare in modo più aggressivo (più bit al secondo per hz) genera molta più vulnerabilità. Oggi i dispositivi hanno un bitrate adattivo che si regola su base di come è messo il canale

9.5 Il WiFi (Ieee 802.11)

Viene utilizzata la banda DSM, e la frequenza su cui viaggiano i segnali è a 2,4 oppure 5 ghz.. Mi fa strano il fatto che lo sto davvero specificando, ma procediamo. Questo protocollo ha più versioni di se stesso dei videogiochi di Pokemon, infatti si hanno svariate versioni

- 802.11b : 2,4 Ghz $\rightarrow 1 - 11 \frac{Mbit}{s}$
- 802.11c : 2,4 Ghz $\rightarrow 1,5 - 54 \frac{Mbit}{s}$
- 802.11a : 5 Ghz $\rightarrow 54 \frac{Mbit}{s}$

- 802.11n : 2,4 / 5 Ghz $\rightarrow 150 \frac{Mbit}{s}$
- 802.11ac : 2,4 / 5 Ghz $\rightarrow 1 \frac{Gbit}{s}$
- 802.11ax : 2,4 / 5 Ghz / 6 Ghz $\rightarrow 10 \frac{Gbit}{s}$

Chiunque può operare una 801.11 purchè abbia degli apparati certificati per operare. Sia nel 2,4 che nel 5 Ghz la frequenza centrale dei canali e la loro spaziatura non sono tali da evitare interferenze tra canali. Nel caso del 2,4 ghz posso avere fino a 13 canali affiancati, ma se mi posiziono su un ipotetico canale, quelli ad esso vicini verranno disturbati.

Come funziona una rete wifi? Hai una serie di terminali che si collegano all'access point direttamente. Ogni tot di tempo vengono generati dei beacon frames (bisogna configurare l'access point) e si ottengono tre forme di associazione

1. Passive scan
2. Assoc.request
3. Assoc.response

Una volta associati poi bisogna autenticarsi e i meccanismi poi di autenticazione diversi (chiave simmetrica, password, chiave asimmetrica, certificati etc.)

Active scan: Il terminale prima invia un messaggio di **probe request**, l'access point risponde con un probe response, e da qui si riprendono i due assoc.

9.5.1 La gestione delle "collisioni"

Il vecchio CSMA/CD non è applicabile perchè via radio non è possibile capire se ci sono delle interferenze, perciò si implementa un meccanismo che invece di rilevare la collisione, punta ad evitarle, questo meccanismo è il CSMA/CA (La A sta per avoidance.)

Come funziona? L'idea di base dietro il protocollo CSMA/CA è il principio "Listen before Talk", ciò vuol dire che deve prima di tutto essere verificato se la linea sia libera ("idle"), prima che la stazione possa iniziare una trasmissione. Ma questo è solo il primo passo: vi sono anche altre funzioni all'interno del processo che consentono di evitare la maggior parte delle collisioni.

I tempi di attesa: Maggiore è il tempo di attesa, maggiore sarà la priorità, pertanto gli ack praticamente hanno sempre la priorità massima, e quando si becca una collisione si ha un meccanismo di backoff esponenziale. E finchè ci son trasmissioni in corso, il mio backoff esponenziale NON si scala, questo succede solo quando è LIBERO.

Come si nota l'obbiettivo sta nell'evitare la collisione più che nel rilevarla

9.5.2 RTS e CTS

Questo procedimento precede la vera e propria trasmissione dei dati. Se un partecipante stabilisce che il mezzo trasmissivo è libero, il dispositivo invia prima di tutto un frame RTS al partecipante che dovrebbe essere il destinatario dei dati.

E' tipo chiedere "che si può per caso?"

In questo caso il computer di partenza rende chiaro che vorrebbe iniziare una trasmissione e occupare così il mezzo trasmissivo per un certo periodo.

Il destinatario invia a sua volta un frame **CTS** al trasmittente originario. In questo modo da una parte vengono informati tutti gli altri partecipanti che si trovano nella stessa estensione, com'è il caso con il frame RTS, e dall'altra il trasmittente riceve il via libera per la trasmissione. Solo allora il dispositivo originario comincia la trasmissione dei dati.

Ora, non è possibile per i partecipanti in una rete wifi stabilire l'insorgenza di collisioni o altri disturbi nella trasmissione. Per questo motivo è necessario che la stazione di destinazione invii una conferma (ACK), non appena il pacchetto sarà arrivato correttamente.

Se il frame ACK non arriva, il trasmittente dei dati presume che sia sopraggiunta una complicazione e invia di nuovo il pacchetto. La stazione ha in questo caso il diritto di priorità sull'utilizzo del mezzo, non deve quindi di nuovo aspettare finché il canale sarà libero.

Quali sono i vantaggi e svantaggi? Per mandare un singolo byte devo fare un pandemonio inutile di passaggi tra cts rts csma etc., MA si migliora l'efficienza di rete generale.

Precisazione: Ogni access point è praticamente (visto da tutti i dispositivi cablati tipo router etc) uno switch, nel senso che cts rts etc esistono solo tra access point e i suoi terminali, ma dopo quello che accade è il normale 802.3

9.6 La rete cellulare

Si hanno delle base stations oppure NodeB oppure eNodeB, son reti che usano bande licenziate, assegnate dallo stato ad un concessionario avente diritto esclusivo di usarle (dopo aver pagato centinaia di milioni di euro per questo diritto). Ci son le varie generazioni:

- 2G GSM
- 3G UMTS
- 4G LTE (o LTE-A)
- 5G

Sia 2G che 3G stanno venendo dismesse, probabilmente le 2g rimangono vive per il fatto che in giro per l'Italia ci son decine di migliaia di sistemi di controllo (tipo le caldaie in montagna) che usano il 2g. Vi ricordate prima del 2g? Quando sul tuo vecchio telefono con i tasti aprivi per sbaglio internet e ti ritrovavi più indebitato del Burundi? Ecco, oggi

con 4G e 5G non c'è più questo problema.

Precisazione: Dal 4g in poi si ha finalmente un indirizzo IP, tutto IP, vero e proprio, prima invece questa cosa non c'era.. Impensabile. Però c'è un problema, cioè in pratica tu hai un IP, ma cambia continuamente sulla carta, perchè se sei in una determinata rete e poi cambi, dovrebbe cambiarti anche l'ip...

Il tunneling risolve questa situazione, nel senso che continui a fare tipo dei tunnel con le shell per una supermegaipergigantissima macro rete che contiene tutti quanti. L'indirizzo è l'ip V6, mentre dentro una rete bastano e avanzano gli ipv4... A meno che in casa abbiate $2^{32} + 1$ dispositivi diversi in casa.